


1.

a.) konštantná variancia

porušenie , kód z matlabu :

$$y(t) = \text{sum}(\text{rand}(1,t)*4.- 2);$$

Obrazok



b.) **Konštantná stredná hodnota**

Príklad aj obrázkom je v 2.b)


Variancia je v tomto prípade konštantná, ale stredná hodnota postupne rastie

$$y(t) = 0.8*t + \text{rand}()*10 - 5;$$

c.) **Autokovariacná funkcia závisí len medzi X[t] a X[t+h] závisí len od t1 a t2]**


npr. časový rad z úlohy 2.c) upravený tak, že epsilon by bolo medzi <-c,+c>
matlab kód:

$$y(t) = y(t-1) + \text{rand}()*4 - 2;$$




2.)

a.) Nie je stacionarný, pretože so stúpajúcim t stúpa aj hodnota sumy teda aj stredná hodnota. Takto ten rad vyzerá. Vidíme, že trend lineárne stúpa a teda stúpa aj stredná hodnota aj variácia. Chyba sa totiž kumuluje.




Ak by epsilon bolo v intervale $<-c, +c>$ rad by nemal lineárny trend, ale stále by nebol stacionárny, pretože by variácia postupne so stupajúcim časom rastla.

b.) Opäť je to rad s lineárnym trendom. Preto nemôže byť stacionárny. Stredná hodnota nie je v tomto prípade konštantná. Teda nie je stacionárny.



c.) Trend je opäť lineárny Teda opäť je nestacionárny. Tiež závisí hodnota v t od hodnoty v (t-1). Toto je všetko za predpokladu že $\epsilon = \langle 0, \text{var}^2 \rangle \rightarrow$ kvôli tomuto rad získava rastuci trend.



3.)

Multiplikatívna sezónnosť

- rozdiel medzi amplitúdami v rámci jednej sezóny rastie.
- rad sa správa nasledovne:

$$y(t) = \text{trend}(t) * \text{seasonality}(t) + e(t)$$

$e(t)$ = náhodný šum

Aditívna sezónnosť

- rozdiel medzi amplitúdami v rámci jednej sezóny konštantný.
- rad sa správa nasledovne

$$y(t) = \text{trend}(t) + \text{seasonality}(t) + e(t)$$

$e(t)$ = náhodný šum


Na nasledovnom obrázku máme dva konkrétne časové rady

$$y(t) = 5.\sin(t) + 0.5*t$$

červený , aditívny. Vidíme, že priamky ohraničujúce amplitúdy sú medzi sebou vodorovné

$$y(t) = 0.25.t*\sin(t) + 0.5*t$$

modrý, multiplikatívna sezónnosť, priamky zvierajú uhol, rozdiel medzi amplitúdami rastie



4.

Výsledky jednotlivých metód pre 2-krokovú predikciu.

Original data : [854.0, 661.0]
 Single Smoothing forecast : [665.21, 683.15]
 Double Smoothing forecast : [730.79, 754.22]
 Tripple Smoothing forecast : [806.03, 650.56]

S tým, že predtým som hľadal' najlepš'í model, tak že som skusal jednotlivé hodnoty alfa, beta, gama pre všetky metódy. Výsledky:

Best Model 1 : alpha = 0.3, MSE = 16954.467181695836
 Best Model 2 : alpha = 0.1, beta = 0.18, MSE = 6851.948125840036
 Best Model 3 : alpha = 0.16, beta = 0.31, gama = 0.76, MSE = 251.58424632733784

MSE bolo počítané na poslednej sezóne, teda na posledných 4 bodoch. (predikované posledné 4 hodnoty verzus reálne.)

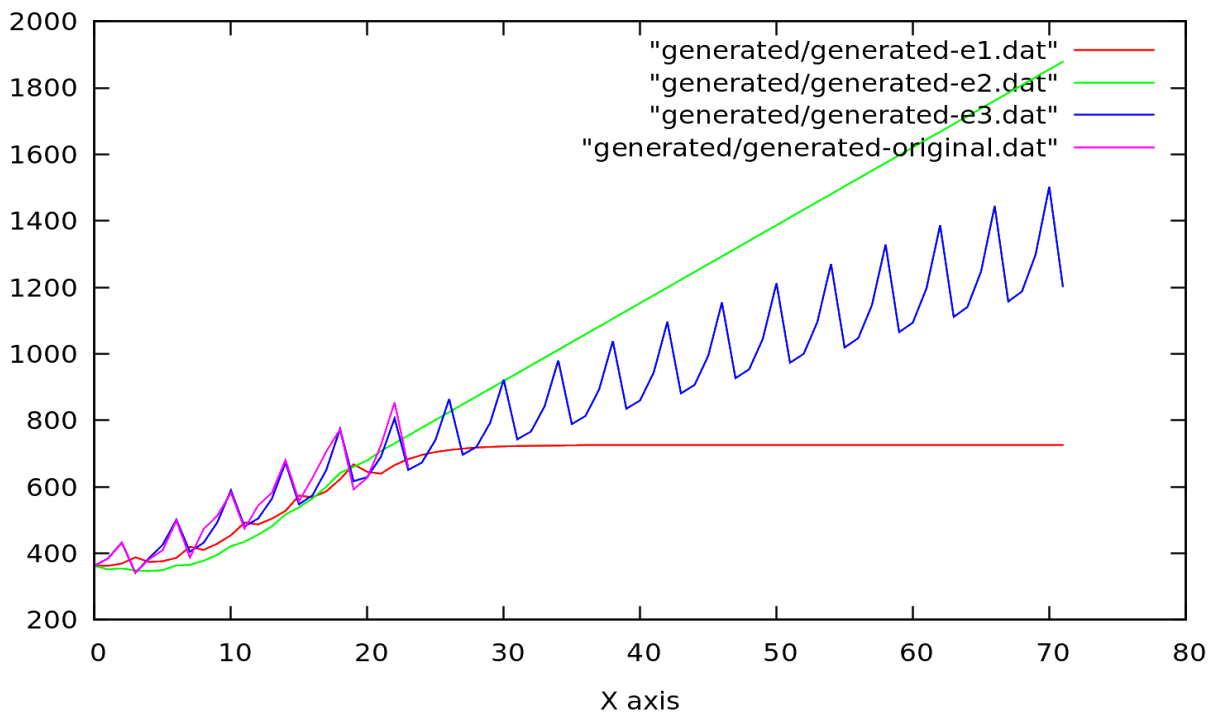
MSE = Mean Square error

Upozorňujem, že program sa dá spustiť. Treba spustiť skript run.sh (samozrejme na linuxe) a pozrieť si -help. Dá nastavovať aj počet krokov predikcie → npr. ./run.sh -f 50 → bude predpovedať 50 krokov.

Grafy predpovedí vyzerali nasledovne. (50 krokova predikcia)

Ako môžeme vidieť, cez *Single Exponential Smoothing* očakávané nie sme schopní predpovedať hodnoty ani trend do budúcnosti (generated-e1)

Double exponential smoothing dokáže síce nejakým spôsobom napodobniť trend, ale nevieme sa vysporiadať so sezónnosťou krivky. (e2)



Posledná tretia (modrá) krivka je predpovedaná pomocou *Tripple exponential smoothing*
Ako vidíme táto metóda nám pekne dokáže predpovedať hodnoty, ktoré berú do úvahy trend aj sezónnosť a teda pre tento časový rad dokáže aj najlepšie predpovedať hodnoty do budúcnosti.

Upozorňujem, že prvý graf robí predikciu 50 krokov!!!!!!!!!! Hodnoty predikcie 2 krokov podľa zadania sú vyznačené hore.

Tiež pridávam graf s vyhladenými radmi $S(t)$ (pozn. smooth) pre jednotlivé metódy
Pre Single exponential smoothing je vyhladený a predikovaný rad totožný.

